

INSTITUTO TECLAB
TECNICATURA EN DATA SCIENCE

PREDICCIÓN DE VENTAS Y OPTIMIZACIÓN DE
INVENTARIO PARA UN RETAIL MULTICATEGORÍA

ANÁLISIS DE DATOS DE SUPERSTORE SALES MEDIANTE
TÉCNICAS DE MACHINE LEARNING

Informe de Tesis presentado para obtener el título

Técnico en Ciencia de Datos

Autor: Ayala Rodrigo Nicolás
Director/Tutor: Sebastian Boari
Fecha: 5 de Marzo del 2026

INTRODUCCIÓN

Problema

En el sector minorista (retail), la gestión eficiente del inventario representa uno de los desafíos más críticos para la rentabilidad y satisfacción del cliente. Según estudios del sector, el 63% de los consumidores optará por otra marca en lugar de esperar que un producto vuelva a estar disponible. Esta realidad se vuelve aún más compleja en un superstore, que ofrece una amplia variedad de productos que van desde muebles y útiles de oficina hasta equipamiento tecnológico, segmentados para consumidores particulares, oficinas corporativas y hogares .

El problema central que se abordará es la dificultad de anticipar las ventas futuras en un contexto de alta variabilidad de productos, estacionalidad marcada y comportamientos de compra heterogéneos según la región y el segmento de cliente. Sin una herramienta predictiva, el negocio enfrenta dos riesgos:

- Falta de stock en productos de alta demanda, lo que genera pérdida de ventas y clientes insatisfechos.
- Exceso de inventario en productos de baja rotación, lo que incrementa costos de almacenamiento y riesgo de obsolescencia.

En base a esto, ¿es posible desarrollar un modelo predictivo que, a partir de datos históricos de ventas, permita anticipar la demanda futura y generar recomendaciones accionables para optimizar la gestión del inventario?

Objetivo

Desarrollar un modelo de machine learning que permita predecir las ventas futuras de un superstore, con el fin de generar recomendaciones basadas en datos para la optimización del inventario.

Objetivos específicos:

1. Realizar un análisis exploratorio de los datos históricos de ventas para identificar patrones de estacionalidad, productos más rentables y comportamiento por región.
2. Implementar y comparar diferentes modelos predictivos (regresión lineal, random forest, XGBoost) para determinar cuál ofrece mayor precisión en la estimación de ventas.
3. Identificar las variables más influyentes en las ventas mediante técnicas de interpretabilidad de modelos.
4. Simular escenarios de mejora a partir de los resultados obtenidos, proponiendo acciones concretas.
5. Entregar un informe con recomendaciones prácticas basadas en evidencia.

Métrica de éxito: El modelo deberá alcanzar un RMSE (error cuadrático medio) inferior a [valor a definir post-EDA] en el conjunto de test, y las recomendaciones deberán estar respaldadas por al menos dos simulaciones cuantificadas.

Contexto de los datos

El dataset seleccionado para este proyecto es "Superstore Sales", un conjunto de datos ampliamente utilizado en la comunidad de ciencia de datos para análisis de retail y predicción de ventas .

Origen de los datos: El dataset está disponible públicamente en la plataforma Kaggle y representa ventas reales de un superstore estadounidense durante un período de cuatro años (aproximadamente 2014-2017) .

Características principales del dataset:

- Volumen: Aproximadamente 10,000 registros de ventas y 18 a 21 columnas informativas .
- Alcance geográfico: Ventas distribuidas en diferentes estados y regiones de Estados Unidos, con presencia en 529 ciudades .
- Categorías de productos: La tienda comercializa tres grandes categorías: Technology (tecnología), Furniture (muebles) y Office Supplies (útiles de oficina) .
- Segmentos de clientes: Los compradores se agrupan en tres segmentos: Consumer (consumidor particular), Corporate (empresas) y Home Office (oficina en casa) .
- Variables disponibles: El dataset incluye información detallada de cada transacción: fecha de pedido, fecha de envío, modo de envío, identificador de cliente, nombre del cliente, segmento, país, ciudad, estado, región, categoría de producto, subcategoría, nombre del producto, cantidad vendida, precio unitario, descuento aplicado y beneficio generado .

Limitaciones a considerar:

- El dataset corresponde a un único superstore, por lo que los resultados pueden no ser generalizables a otras cadenas o contextos geográficos.
- No incluye información sobre factores externos como clima, eventos locales o condiciones económicas que podrían influir en las ventas.
- Los datos abarcan un período limitado (4 años), lo que puede restringir la identificación de tendencias a largo plazo.

A pesar de estas limitaciones, el dataset ofrece una base sólida para aplicar técnicas de análisis exploratorio, modelado predictivo y generación de recomendaciones, cumpliendo con los objetivos planteados para el desarrollo.

PREPARACIÓN Y LIMPIEZA DE DATOS

Previo al análisis exploratorio, se realizó una etapa de preparación de los datos con el objetivo de garantizar su calidad y consistencia. El dataset original, proveniente de un archivo Excel con 9.994 registros de ventas y 21 columnas, fue sometido a un proceso de estandarización de tipos de datos. Las columnas de texto, que originalmente estaban clasificadas como "object", fueron convertidas al tipo "string" para optimizar su manejo y permitir operaciones más eficientes durante el análisis. Asimismo, las columnas de fecha ("Order Date" y "Ship Date") fueron transformadas al formato datetime, lo que permitió posteriormente crear variables temporales derivadas como año, mes, trimestre y día de la semana, facilitando así los análisis de estacionalidad.

Posteriormente, se realizó una verificación exhaustiva de la integridad de los datos, enfocada en la detección de valores nulos o faltantes. Los resultados fueron óptimos: se confirmó que ninguna de las 209.874 celdas que componen el dataset presenta valores ausentes, alcanzando un 100% de completitud en todos los registros y columnas. Esta condición es ideal para el análisis, ya que elimina la necesidad de aplicar técnicas de imputación o eliminación de datos, preservando la totalidad de la información original y garantizando que los patrones y conclusiones que se deriven del estudio sean representativos de la realidad operativa del negocio.

ANÁLISIS EXPLORATORIO

El análisis consistió en el tratamiento de los datos históricos de ventas, estructurado en tres secciones que responden directamente a los objetivos de la investigación. La primera sección aborda la estacionalidad, examinando el comportamiento de las ventas a nivel trimestral, por categoría de producto, durante eventos específicos como Black Friday y Navidad, y su impacto en la rentabilidad mensual. La segunda sección identifica los productos más rentables, analizando el beneficio por categoría, subcategoría y a nivel de producto individual. Finalmente, la tercera sección evalúa el comportamiento por región, comparando el desempeño de ventas y beneficios entre regiones, su relación con las categorías de producto y la estacionalidad regional.

Insights general

El análisis revela que el negocio presenta una fuerte estacionalidad concentrada en el cuarto trimestre (Q4), donde las ventas alcanzan su punto máximo, especialmente en diciembre (2% sobre el promedio), mientras que enero constituye el mes más débil (-7% bajo el promedio). Esta estacionalidad está liderada por la categoría Technology, que no solo es la más estacional sino también la más rentable, dominando las ventas navideñas y mostrando un pico secundario en Q3 asociado a la vuelta al cole.

Sin embargo, la rentabilidad no se distribuye uniformemente: la subcategoría Copiers emerge como la más rentable a nivel agregado, y el producto estrella es la Fellowes PB500, lo que sugiere que los equipos de oficina de alto valor añadido generan márgenes superiores. A nivel geográfico, la región West lidera en rentabilidad, superando por 2.7x a la región Central, la de menor desempeño, lo que indica posibles problemas de gestión, costos logísticos o políticas de descuento diferenciadas.

La combinación de estos hallazgos sugiere que la estrategia comercial debe ser diferenciada: potenciar Technology en Q4 con inventario y marketing agresivo, aprovechar la estabilidad de Office Supplies para generar flujo constante, y revisar la rentabilidad de Furniture y la región Central, donde podrían estar ocurriendo pérdidas encubiertas por altos volúmenes de venta con bajos márgenes.

MODELO BASELINE

Como punto de partida para el análisis predictivo, se implementaron dos modelos baseline: Regresión Lineal Múltiple y Random Forest. El objetivo fue establecer un rendimiento de referencia que permita evaluar mejoras posteriores. Ambos modelos se entrenaron utilizando 33 features, incluyendo variables temporales (día, mes, año, día de semana), numéricas (cantidad, descuento) y categóricas codificadas (categoría, subcategoría, segmento, región, modo de envío). Se realizó una división temporal estricta (80% train, 20% test) respetando el orden cronológico de las transacciones para evitar data leakage.

Los resultados obtenidos muestran que la Regresión Lineal alcanzó un R^2 de 0.261 y un RMSE de \$253,401.17, mientras que Random Forest obtuvo un R^2 de 0.212 y un RMSE de \$270,413.81. Contrario a lo esperado, la regresión lineal superó a Random Forest en aproximadamente 5 puntos porcentuales en R^2 , lo que sugiere que la relación entre las variables y las ventas podría ser predominantemente lineal, o que el modelo de árbol requiere un ajuste en sus hiperparámetros.

El análisis de la importancia de variables revela patrones consistentes y valiosos. En Random Forest, las variables más influyentes son Quantity (18.1%), Day (13.6%) y Month (11.4%), lo que confirma el rol fundamental del volumen de compra y la estacionalidad en las ventas. Por su parte, la Regresión Lineal (con coeficientes estandarizados) identifica a Sub-Category_Copiers y Sub-Category_Machines como los predictores de mayor impacto positivo, indicando que son productos de alto valor unitario que incrementan significativamente el ticket promedio. En contraste, variables como Sub-Category_Furnishings y Category_Office Supplies presentan coeficientes negativos, reflejando que son productos de bajo costo que, si bien contribuyen a la facturación total, están asociados a transacciones de menor valor.

Estos hallazgos preliminares aportan insights accionables: los productos de alto impacto (Copiers, Machines) requieren prioridad en la gestión de inventario por su capacidad de elevar el ticket promedio. En contraste, los productos de bajo ticket (Office Supplies, Furnishings) no deben desestimarse, sino aprovecharse mediante estrategias de venta cruzada (cross-selling); al ofrecerlos como complemento durante la compra de productos de alto valor, maximizando así el ingreso por transacción.

PRÓXIMAS ETAPAS

A partir de los resultados obtenidos en esta fase inicial, se identifican las siguientes líneas de trabajo para la continuación del proyecto:

1. Incorporación de XGBoost como modelo avanzado

Se implementará XGBoost con optimización de hiperparámetros mediante validación cruzada temporal. Este modelo probablemente ofrezca mejor rendimiento que Random Forest en datos tabulares, y se compararán sus métricas (R^2 , RMSE) con los modelos baseline para determinar si supera a la regresión lineal.

2. Ajuste de hiperparámetros en Random Forest

Dado que Random Forest se implementó con parámetros por defecto y obtuvo un rendimiento inferior a la regresión lineal (R^2 0.212 vs 0.261), se realizará una búsqueda acotada de hiperparámetros (`n_estimators`, `max_depth`) para evaluar si puede alcanzar un mejor desempeño.

3. Simulación de escenarios de mejora

Se diseñarán simulaciones basadas en los modelos optimizados para:

- Cuantificar el impacto de aumentar descuentos en categorías específicas (ej: Tecnología)
- Optimizar el inventario de productos de alta en el stock

5. Desarrollo de una herramienta de apoyo a la toma de decisiones

Utilizando los modelos finales y las simulaciones que se generarán en la fase siguiente, se construirá una aplicación o herramienta interactiva. Esta herramienta servirá como soporte para la toma de decisiones relacionadas con la gestión de inventarios y la planificación de estrategias comerciales, dando así respuesta a la pregunta central planteada al inicio del estudio.

BIBLIOGRAFÍA

- ☐ Flame Analytics. (s.f.). Modelos de predicción en retail: Cómo anticipar la demanda, optimizar staff y medir el impacto de las promociones. Recuperado el 14 de Febrero del 2026, de <https://flameanalytics.com/es/modelos-de-prediccion-en-retail-como-anticipar-la-demanda-optimizar-staff-y-medir-el-impacto-de-las-promociones/>
- ☐ SayamAlt. (s.f.). Superstore-Sales-Prediction. GitHub. Recuperado el 14 de Febrero del 2026, de <https://github.com/SayamAlt/Superstore-Sales-Prediction>
- ☐ Orisha. (s.f.). Análisis predictivo para una gestión de stock inteligente. Recuperado el 14 de Febrero del 2026, de <https://commerce.orisha.com/es/blog/analisis-predictivo-gestion-stock/>
- ☐ Resan, S. (s.f.). Superstore Sales Analysis. LinkedIn. Recuperado el 14 de Febrero del 2026, de <https://www.linkedin.com/pulse/superstore-sales-analysis-sandra-resan/>
- ☐ Bardi, F. (s.f.). Super Store Sales Analysis. Medium. Recuperado el 14 de Febrero del 2026, de <https://medium.com/@frnbardi/super-store-sales-analysis-f33388d7ea73>
- ☐ Oracle. (s.f.). Optimización de comercialización. Recuperado el 14 de Febrero del 2026, de <https://www.oracle.com/latam/data-platform/merchandising-optimization/>